

Authorship Classification

Seminarski rad u okviru kursa

Istraživanje podataka 2

Matematički fakultet

Zagorka Pantović

mi20227@alas.matf.bg.ac.rs

Avgust 2026.

Sažetak

U ovom radu analiziran je problem identifikacije autora teksta korišćenjem metoda mašinskog učenja (eng. *machine learning*). Cilj istraživanja je razvoj modela koji na osnovu teksta novinskog članka može da predvidi njegovog autora.

Korišćen je skup podataka Reuters C50 koji sadrži 5000 novinskih članaka napisanih od strane 50 različitih autora. Rad obuhvata kompletnu analitičku proceduru koja uključuje analizu podataka, obradu teksta, ekstrakciju atributa pomoću TF-IDF metode, vizualizaciju u 2D i 3D prostoru, kao i treniranje i evaluaciju sedam klasifikacionih algoritama na tri različita skupa atributa (ukupno 21 model).

Testirani su: Multinomial Naive Bayes, Complement Naive Bayes, Logistic Regression, Linear Support Vector Machine, K-Nearest Neighbors, Random Forest i Decision Tree. Rezultati pokazuju da Linear SVM postiže najbolje performanse sa tačnošću klasifikacije od **72.4%** na punom skupu od 10 000 TF-IDF atributa.

Eksperimenti su takode pokazali da redukcija broja atributa sa 10 000 na 2 000 ima minimalan uticaj na performanse linearnih modela (pad od svega ≈ 1.5 pp), dok dalje smanjenje na 500 atributa dovodi do primetnog pada tačnosti kod svih algoritama.

0 Sadržaj

1	Uvod	3
2	Opis podataka	3
2.1	Reuters C50 dataset	3
2.2	Statistike sirovih podataka	4
3	Preprocesiranje podataka	5
3.1	Koraci preprocesiranja	5
3.2	Domenske stop-reči	5
3.3	Efekat preprocesiranja	6
4	Vizualizacija podataka u 2D i 3D prostoru	7
4.1	TF-IDF vektorizacija za vizualizaciju	7
4.2	SVD redukcija dimenzionalnosti	7
4.3	PCA vizualizacija	8
4.4	t-SNE vizualizacija	8
5	TF-IDF vektorizacija i klasifikacija	9
5.1	TF-IDF vektorizacija	9
5.2	Klasifikacioni algoritmi	9
6	Rezultati klasifikacije	10
6.1	Accuracy po algoritmu i skupu atributa	10
6.2	Analiza rezultata	10
6.3	Poređenje svih metrika (puni skup atributa)	11
7	Detaljna evaluacija	12
7.1	Confusion matrica (SVM, puni skup)	12
7.2	Analiza tačnosti po autorima	13
7.3	Classification Report (SVM, puni skup)	14
7.4	Cross-validacija	15
7.5	Najvažnije reči po autoru (SVM koeficijenti)	16
7.6	Finalno poređenje modela	17
8	Zaključak	17
	Literatura	19

1 Uvod

Ovaj seminarski rad bavi se problemom **klasifikacije autora novinskih tekstova** primenom metoda mašinskog učenja nad Reuters C50 datasetom. Cilj je izgraditi model koji može da prepozna autora članka na osnovu samog teksta, bez ikakvih metapodataka.

Atribucija autorstva teksta (*authorship attribution*) je klasičan problem u obradi prirodnog jezika koji ima primene u forenzičkoj lingvistici, detekciji plagijata i analizi stilometrike. Ključni izazov leži u tome što različiti autori mogu pisati o sličnim temama, pa model mora da nauči stilske, a ne samo tematske razlike.

U ovom radu:

- Analiziramo i vizualizujemo Reuters C50 dataset,
- Primenjujemo preprocesiranje teksta (uklanjanje stop-reči, stemovanje),
- Vektorizujemo tekstove pomoću TF-IDF metode sa tri različita skupa atributa,
- Treniramo i poredimo **7 klasifikatora** na **3 skupa atributa** (ukupno 21 model),
- Evaluiramo modele pomoću višestrukih metrika i cross-validacije,
- Analiziramo koje attribute (reči) modeli smatraju najvažnijim.

Celokupan kod napisan je u programskom jeziku Python i organizovan u 5 Jupyter notebook-ova.

2 Opis podataka

2.1 Reuters C50 dataset

Reuters C50 dataset potiče sa UCI Machine Learning Repository-ja (<https://archive.ics.uci.edu/dataset/217/reuter+50+50>). Sadrži novinske članke Reuters novinarske agencije, napisane od strane 50 različitih novinara.

Tabela 1: Osnovne karakteristike Reuters C50 dataseta

Karakteristika	Vrednost
Ukupan broj dokumenata	5000
Broj autora (klasa)	50
Dokumenti za trening	2500 (50 po autoru)
Dokumenti za testiranje	2500 (50 po autoru)
Tip podataka	Tekstualni fajlovi (.txt)
Prosečan broj reči	505.7 reči/dokumentu
Prosečan broj karaktera	3102.9 kar./dokumentu
Ciljni atribut	Ime autora (50 kategorija)

Dataset je organizovan u dva foldera: **C50train** (trening skup) i **C50test** (test skup). Unutar svakog foldera postoji po jedan podfolder za svakog od 50 autora, a u njemu tačno 50 tekstualnih fajlova. Ovakva organizacija garantuje **savršeno balansiran dataset** — svaka klasa ima identičan broj instanci.

Lista autora obuhvata novinare različitog porekla i geografskog fokusa: anglosaksonski dopisnici (AaronPressman, BradDorfman), azijski dopisnici (FumikoFujisaki, BenjaminKangLim, JaneMacartney, WilliamKazer), evropski dopisnici (JanLopatka, JohnMastrini) i mnogi drugi.


2.2 Statistike sirovih podataka

Tabela 2: Deskriptivna statistika broja reči po dokumentu (sirovi tekst)

Statistika	Broj reči	Broj karaktera
Prosek	505.7	3102.9
Std. dev.	135.5	826.2
Minimum	51	348
25% kvartil	425	2610
Medijana	510	3124
75% kvartil	579	3549
Maksimum	1499	8811

Prosek (505.7) i medijana (510) su veoma bliske, što ukazuje na simetričnu raspodelu. Postoji određeni broj outliera — veoma kratkih (< 100 reči) i veoma dugačkih (> 900 reči) tekstova.

Između autora postoje značajne razlike u prosečnoj dužini tekstova: **PeterHumphrey** piše najduže tekstove (prosek 598 reči), dok **JimGilchrist** i **LydiaZajc** pišu znatno kraće (prosek ≈ 334 reči) — razlika od gotovo 80%.




(a) Broj dokumenata po autoru (train/test)

(b) Distribucija dužine tekstova

Slika 1: Osnovna eksploracija Reuters C50 dataseta

Grafikon 1a potvrđuje savršenu balansiranost dataseta — svaki autor ima tačno 50 train i 50 test dokumenata. Grafikon 1b prikazuje distribuciju broja reči (levo) i karaktera (desno) koja je bliska normalnoj sa blagom pozitivnom asimetrijom.



Slika 2: Raspodela broja reči — 10 autora s najdužim i 10 s najkraćim tekstovima

Boxplot na slici 2 otkriva da autori s dugačkim tekstovima (PeterHumphrey, LynneO'Donnell) imaju i veću varijabilnost u dužini, dok autori kratkih tekstova pišu konzistentno.

3 Preprocesiranje podataka

3.1 Koraci preprocesiranja

Sirovi novinski tekstovi sadrže šum koji otežava klasifikaciju: HTML/XML tagove, interpunkciju, brojeve, gramatičke reči bez semantičke vrednosti i varijante iste reči u različitim morfološkim oblicima. Primljeni su sledeći koraci preprocesiranja:

1. **Uklanjanje HTML/XML tagova** — regularnim izrazom `<[>]+>`
2. **Filtriranje znakova** — zadržavaju se samo slova i razmaci
3. **Lowercase normalizacija** — svi tokeni se pretvaraju u mala slova
4. **Tokenizacija** — deljenje teksta na reči
5. **Uklanjanje stop-reči** — standardne engleske stop-reči (NLTK) + domenske
6. **Filtriranje kratkih tokena** — uklanjaju se reči kraće od 3 karaktera
7. **Stemovanje (Porter Stemmer)** — svođenje reči na koren oblika

3.2 Domenske stop-reči

Pored standardnih engleskih stop-reči, dodato je i 24 domenske stop-reči specifičnih za Reuters novinske tekstove:

reuters, said, say, says, year, years, new, also, would, could, may, one, two, three, inc, corp, lt, dlrs, mln, bln, pct, vs, told, added


Reči poput *said* i *reuters* pojavljuju se u skoro svakom tekstu i ne doprinose razlikovanju autora.

3.3 Efekat preprocesiiranja


Tabela 3: Efekat preprocesiranja na broj reči

Metrika	Pre	Posle	Smanjenje
Prosečan broj reči	505.7	275.8	45.5%
Std. devijacija	135.5	74.8	44.8%
Minimum	51	31	—
Medijana	510	276	45.9%
Maksimum	1499	797	—

Preprocesiranje je smanjilo prosečan broj reči za **45.5%** — gotovo polovina svih reči su bile stop-reči, interpunkcija i brojevi bez semantičke vrednosti. Distribucija ostaje simetrična (prosek $\approx$ medijana = 276 reči).



Slika 3: Vizualizacija efekta preprocesiranja na broj reči po dokumentu i autoru



Slika 4: Analiza frekvencije reči

Pre preprocesiranja, top 20 reči su isključivo gramatičke stop-reči (*the, to, of, a, in, and, said...*). Nakon preprocesiranja, top reči su smisleni finansijski termini: **compani, percent, million, market, analyst, share, china, bank, billion** — što odgovara tematici Reuters agencije. Prisustvo reči *china, hong, kong* ukazuje na značajnu pokrivenost azijskog tržišta.

4 Vizualizacija podataka u 2D i 3D prostoru


4.1 TF-IDF vektorizacija za vizualizaciju

Pošto tekstualni podaci nemaju direktnu prostornu reprezentaciju, koristimo tehnike redukcije dimenzionalnosti za vizualizaciju. TF-IDF matricu dimenzija 5000×5000 (96.8% nula) nije moguće direktno vizualizovati, pa je primenjena sledeća pipeline:

$$\text{Tekst} \xrightarrow{\text{TF-IDF}} \mathbb{R}^{5000} \xrightarrow{\text{SVD}} \mathbb{R}^{100} \xrightarrow{\text{PCA/t-SNE}} \mathbb{R}^{2/3}$$

4.2 SVD redukcija dimenzionalnosti


TruncatedSVD je primenjen kao predkorak koji radi direktno na retkim matricama.



Slika 5: Scree plot — kumulativna objašnjena varijansa (TruncatedSVD, 100 komponenti)

Sa 100 SVD komponenti objašnjava se samo **27.2%** ukupne varijanse. Kriva raste postepeno bez strme „laktične” tačke, što je karakteristično za visoko-dimenzionalne tekstualne podatke — informacija je ravnomerno rasuta po svim dimenzijama i ne može se efikasno kompresovati.

4.3 PCA vizualizacija




(a) PCA 2D projekcija (PC1=6.30%, PC2=3.53%) (b) PCA 3D projekcija (ukupno 12.94%)

Slika 6: PCA vizualizacija svih 5000 dokumenata obojenih po autoru

PC1 objašnjava 6.30%, a PC2 3.53% varijanse — zajedno svega 9.83%. Linearna PCA nije dovoljno moćna da razdvoji 50 autorskih stilova na osnovu samo 2–3 dimenzije, pa projekcija prikazuje značajno preklapanje klasa. Ipak, određeni autori su vidljivi kao odvojeni oblaci na rubovima prostora — oni imaju najdistinktivniji vokabular.

4.4 t-SNE vizualizacija



(a) t-SNE 2D (perplexity=30, max_iter=1000)

(b) PCA vs t-SNE — 10 nasumičnih autora

Slika 7: t-SNE vizualizacija i poređenje sa PCA

t-SNE, kao nelinearna metoda koja čuva lokalne susedstvene odnose, pokazuje znatno bolju separaciju klasa od PCA. Vidljivi su kompaktni klasteri za deo autora, posebno one

sa distinktivnim temama (novinari specijalizovani za jednu geografsku oblast ili temu).

Poređenje na 10 autora (desna slika) jasno ilustruje prednost t-SNE: dok PCA prikazuje isprepletane oblake tačaka, t-SNE ih razdvaja u prostorno odvojene grupe. Ovo vizuelno potvrđuje da su autorski stilovi dovoljno distinktivni da ih algoritmi klasifikacije mogu razlikovati u punom dimenzionalnom prostoru.

5 TF-IDF vektorizacija i klasifikacija

5.1 TF-IDF vektorizacija

Za klasifikaciju su kreirana tri TF-IDF skupa atributa različite granularnosti:

Tabela 4: Konfiguracije TF-IDF skupova atributa

Naziv	N-grami	Max features	Dimenzije
Puni skup	unigrami + bigrami	10 000	2500×10000
Redukovani skup	unigrami	2 000	2500×2000
Mali skup	unigrami	500	2500×500

Svi TF-IDF vektorizatori su fitovani **isključivo na train skupu**, a zatim primenjeni (*transform*) na test skup — čime se sprečava curenje informacija (*data leakage*). Korišćeno je sublinearno TF skaliranje ($\text{tf} \rightarrow 1 + \log(\text{tf})$) koje smanjuje uticaj ekstremno čestih reči.

5.2 Klasifikacioni algoritmi

Primenjeno je 7 algoritama koji pokrivaju različite pristupe mašinskom učenju:

Tabela 5: Primenjeni klasifikacioni algoritmi i njihove konfiguracije

Algoritam	Pristup	Ključni hiperparametri
Naive Bayes (Multinomial)	Probabilistički	$\alpha = 0.1$
Naive Bayes (Complement)	Probabilistički	$\alpha = 0.1$
SVM (LinearSVC)	Linearni diskriminativni	$C = 1.0$
Logistic Regression	Linearni diskriminativni	$C = 5.0$, solver=lbfgs
Random Forest	Ansamblski	200 stabala
K-Nearest Neighbors	Baziran na instancama	$k = 5$, metrika: kosinusna
Decision Tree	Stabla odluke	max_depth=50


KNN koristi **kosinusnu metriku** koja je prikladnija za TF-IDF vektore od euklidske — bolje hvata ugaonu sličnost između dokumenata u visokim dimenzijama.

6 Rezultati klasifikacije

6.1 Accuracy po algoritmu i skupu atributa

Tabela 6: Accuracy (%) svih 21 modela

Klasifikator	Mali (500)	Redukovani (2000)	Puni (10000)
SVM (LinearSVC)	66.28	70.88	72.40
Logistic Regression	66.88	70.36	71.04
Naive Bayes (Multinomial)	60.72	65.44	67.52
Random Forest	60.00	63.84	66.20
Naive Bayes (Complement)	51.16	59.20	63.76
K-Nearest Neighbors	55.36	58.72	60.92
Decision Tree	38.16	43.84	45.28




Slika 8: Accuracy (%) po algoritmu i skupu atributa — grouped bar chart

6.2 Analiza rezultata

Iz rezultata se mogu izvući sledeći zaključci:

1. **SVM (LinearSVC)** je globalno najbolji model sa **72.40% tačnosti** i 72.03% macro F1 na punom skupu atributa.
2. **Logistička regresija** je blizu (71.04%), što potvrđuje da linearni modeli dominiraju u klasifikaciji TF-IDF vektora.
3. **Povećanje broja atributa** konzistentno poboljšava sve modele. Dobitak od 500 na 2000 je veći nego od 2000 na 10000, što sugerise zasićivanje krive.
4. **Naive Bayes Complement** je najosjetljiviji na redukciju atributa: gubi 12.6 pp (63.8% → 51.2%) prelaskom sa punog na mali skup.


5. **Decision Tree** je ubedljivo najlošiji (45.3%) — stabla odluke loše generalizuju na retkim visoko-dimenziionalnim TF-IDF matricama.



Slika 9: Uticaj broja TF-IDF atributa na tačnost klasifikacije (log skala)

Slika 9 jasno prikazuje da su krive SVM i LR najravnije (najrobusnije na smanjenje atributa), dok Naive Bayes Complement ima najstrmiji pad.

6.3 Poređenje svih metrika (puni skup atributa)




Slika 10: Heatmap svih metrika klasifikacije — puni skup atributa (10 000 features)

Heatmap na slici 10 pokazuje da su sve četiri metrike (Accuracy, F1 macro, Precision, Recall) međusobno konzistentne — razlika između njih je manja od 1 pp za svaki model. Ovo potvrđuje da je dataset balansiran i da nema dominantnih klasa koje bi narušavale metrike.

7 Detaljna evaluacija

7.1 Confusion matrixa (SVM, puni skup)




Slika 11: Confusion matrixa — SVM (LinearSVC) na punom skupu atributa

Confusion matrixa na slici 11 vizualizuje distribuciju tačnih i pogrešnih predikcija za svih 50 autora. Tamno-plavi dijagonalni elementi označavaju tačne klasifikacije — dominantni su za većinu autora.


Posebno se ističu:

- **Savršeno klasifikovani autori** (100% recall): FumikoFujisaki, JimGilchrist, LynnleyBrowning, KarlPenhaul — svi njihovi dokumenti su tačno prepoznati.
- **Najlošije klasifikovani autori**: ScottHillis (18%), DarrenSchuettler i DavidLawder (po 28%), JaneMacartney (30%).

7.2 Analiza tačnosti po autorima



Slika 12: F1-score po autoru za top 3 modela (puni skup atributa)



Slika 13: Top 10 najlakše i najteže prepoznatljivih autora (prosečan F1 top 3 modela)

Tabela 7: 10 najlakše i 10 najteže prepoznatljivih autora (prosečan F1, top 3 modela)

Najlakši autori		Najteži autori	
Autor	F1	Autor	F1
FumikoFujisaki	0.993	ScottHillis	0.222
KarlPenhaul	0.968	JaneMacartney	0.286
MatthewBunce	0.955	DavidLawder	0.302
JimGilchrist	0.941	DarrenSchuettler	0.324
LynnleyBrowning	0.930	BenjaminKangLim	0.373
AaronPressman	0.904	HeatherScofield	0.382
JoWinterbottom	0.900	MureDickie	0.400
RogerFillion	0.881	WilliamKazer	0.409
JonathanBirt	0.881	TanEeLyn	0.435
MichaelConnor	0.879	ToddNissen	0.462


FumikoFujisaki je najlakši autor za prepoznavanje ($F1 = 0.993$) — verovatno jer piše isključivo o japanskim temama i koristi specifičan vokabular. **KarlPenhaul** (0.968) je ratni izveštač sa visoko distinktivnim temama. Na drugom kraju, **ScottHillis** ($F1 = 0.222$) je ubedljivo najteži — grupu teških autora čine uglavnom dopisnici koji pišu o azijskim tržištima (ScottHillis, JaneMacartney, DavidLawder, BenjaminKangLim, TanEeLyn, WilliamKazer) koji dele sličan vokabular.

7.3 Classification Report (SVM, puni skup)

Tabela 8: Selektovani redovi iz Classification Report — SVM (LinearSVC)

Autor	Precision	Recall	F1-score	Support
FumikoFujisaki	1.000	1.000	1.000	50
KarlPenhaul	0.980	1.000	0.990	50
JimGilchrist	0.893	1.000	0.943	50
LynnleyBrowning	0.926	1.000	0.962	50
MatthewBunce	0.980	0.960	0.970	50
ScottHillis	0.273	0.180	0.217	50
JaneMacartney	0.300	0.300	0.300	50
BenjaminKangLim	0.354	0.340	0.347	50
DarrenSchuettler	0.378	0.280	0.322	50
DavidLawder	0.583	0.280	0.378	50
macro avg	0.731	0.724	0.720	2500
accuracy			0.724	2500

7.4 Cross-validacija




Slika 14: 5-Fold Cross-validacija na train skupu (top 3 modela)

Tabela 9: Rezultati 5-Fold Cross-validacije na train skupu

Model	CV Accuracy	Std. devijacija
SVM (LinearSVC)	86.12%	$\pm 1.65\%$
Logistic Regression	85.28%	$\pm 1.23\%$
NB Multinomial	81.20%	$\pm 2.13\%$

Cross-validacija na train skupu daje znatno više rezultate ($\sim 86\%$) nego evaluacija na test skupu ($\sim 72\%$). Razlika od ≈ 14 pp ukazuje na određeni stepen overfittinga — modeli se bolje snalaze unutar train distribucije. Mala standardna devijacija (1.2–2.1%) znači da su modeli stabilni. NB ima najveću varijabilnost ($\pm 2.13\%$), dok je LR najstabilniji ($\pm 1.23\%$).


7.5 Najvažnije reči po autoru (SVM koeficijenti)



Slika 15: Top 15 karakterističnih reči za 6 autora — SVM koeficijenti

SVM koeficijenti otkrivaju koje reči model smatra najkarakterističnijim za svakog autora. Autori sa jedinstvenim temama (KarlPenhaul — ratni izveštač, FumikoFujisaki — Japan) imaju visoko specifične top reči koje se ne pojavljuju kod drugih autora, što direktno korelira sa njihovim visokim F1 skorovima. Autori koji pišu o azijskim tržištima dele sličan vokabular (china, hong, kong, beijing), što ih čini međusobno nerazlučivima.

7.6 Finalno poređenje modela



Slika 16: Finalno poređenje svih klasifikatora na punom skupu atributa

8 Zaključak

U ovom radu primenjeno je istraživanje podataka na Reuters C50 dataset koji sadrži 5000 novinskih članaka od 50 autora Reuters agencije. Problem klasifikacije autora teksta je rešen primenom 7 algoritama na 3 skupa TF-IDF atributa (ukupno 21 model).

Ključni nalazi:

1. **Najbolji model je SVM (LinearSVC)** sa **72.4%** tačnosti na punom skupu od 10 000 TF-IDF atributa (unigrami + bigrami). Logistička regresija je blizu sa 71.0%.
2. **Linearni modeli dominiraju** — SVM i LR su superiorniji od ansambla (Random Forest), stabla odluke i KNN-a. Ovo je tipično za TF-IDF reprezentacije gde je prostor visokih dimenzija linearno separabilan.
3. **Povećanje broja atributa dosledno poboljšava sve modele**, ali sa smanjenjem prirasta. Dobitak od 500 na 2000 atributa je veći nego od 2000 na 10 000, što sugeriše zasićivanje.
4. **Postoje značajne razlike između autora**: FumikoFujisaki i KarlPenhaul se klasifikuju gotovo savršeno ($F1 > 0.97$), dok ScottHillis i JaneMacartney imaju $F1 < 0.30$. Teški autori su uglavnom dopisnici koji pokrivaju iste teme (azijska tržišta) i dele sličan vokabular.
5. **Cross-validacija** pokazuje stabilnost modela ($\pm 1-2\%$) uz razliku od ~ 14 pp između

train CV ($\sim 86\%$) i test tačnosti ($\sim 72\%$), što ukazuje na određeni nivo overfittinga.

6. **Preprocesiranje** je smanjilo broj reči za 45.5%, uklanjajući šum i zadržavajući semantički bitne termine. Ovo je ključan korak koji direktno utiče na kvalitet klasifikacije.

Moguća poboljšanja:

- Primena neuronskih mreža (BERT, DistilBERT) za dublje semantičke reprezentacije
- Hiperparametarska optimizacija (Grid Search / Bayesian Optimization)
- Proširenje skupa atributa stilometrijskim karakteristikama (prosečna dužina rečenice, raznovrsnost vokabulara, upotreba interpunkcije)
- Primena ansambla top modela (SVM + LR + NB Voting Classifier)

8 Literatura

1. Lichman, M. (2013). *UCI Machine Learning Repository*. University of California, Irvine. <https://archive.ics.uci.edu/dataset/217/reuter+50+50>
2. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
3. Bird, S., Loper, E., & Klein, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.
4. Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
5. Porter, M. F. (1980). *An algorithm for suffix stripping*. Program, 14(3), 130–137.
6. Van der Maaten, L., & Hinton, G. (2008). *Visualizing Data using t-SNE*. Journal of Machine Learning Research, 9, 2579–2605.